Υλοποιητική εξαμηνιαία εργασία

Ανάκτηση πληροφορίας

ΠΑΝΕΠΙΣΤΗΜΙΟ
ΠΑΤΡΩΝ
UNIVERSITY OF PATRAS

Κόλλιας Ιωάννης
1064886
st1064886@ceid.upatras.gr

2022-2023

Πίνακας Περιεχομένων

Περιγραφή Περιβάλλοντος Υλοποίησης

Η υλοποίηση της παρούσας εργασίας έγινε στο περιβάλλον του Microsoft Visual Studio Code σε linux λειτουργικό (Pop!_OS 22.04 LTS) ενώ η γλώσσα προγραμματισμού που χρησιμοποιήθηκε είναι η Python 3.10.6 64bit. Για την εκπόνηση των ερωτημάτων ήταν η απαραίτητη η χρήση των ακόλουθων βιβλιοθηκών:

```
from elasticsearch import Elasticsearch
from elasticsearch import helpers
import csv
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.feature_extraction.text import CountVectorizer
from sklearn.ensemble import RandomForestClassifier
from sklearn.preprocessing import MaxAbsScaler
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn import svm
from sklearn.cluster import KMeans
from matplotlib import pyplot as plt
from sklearn.decomposition import PCA
from sklearn.preprocessing import normalize, MaxAbsScaler
from kneed import KneeLocator
import numpy as np
import seaborn as sns
```

Για την χρησιμοποίηση αυτών ήταν απαραίτητη η εγκατάσταση στο λειτουργικό, με τις ακόλουθες εντολές στο terminal:

- pip install elasticsearch
- pip install scikit-learn
- pip install pandas
- pip install numpy
- pip install seaborn
- pip install kneed

Στην παρούσα εργασία έγινε και μια προσπάθεια για Graphical User Interface (GUI) για την οποία χρειάστηκαν οι βιβλιοθήκες:

```
import tkinter as tk
from tkinter import ttk
from tkinter import messagebox
from tabulate import tabulate
```

όπου για την αξιοποίηση αυτών χρειάστηκαν οι εντολές:

- pip install tkinter
- pip install tabulate

Περιγραφή Διαδικασίας Υλοποίησης

Πριν ξεκινήσει η επεξήγηση των λύσεων των ερωτημάτων κρίθηκε απαραίτητο να υλοποιηθεί ένα στοιχειώδες menu μέσω του terminal προκειμένου να γίνει πιο εύχρηστη η εφαρμογή. Να σημειωθεί πως σε κάθε ερώτημα, όπου αυτό κρίνεται απαραίτητο, θα γίνεται αναφορά στις εισόδους που δέχεται η εκάστοτε λειτουργία.

Ερώτημα Πρώτο

Αρχικά γίνεται η εγκατάσταση της elasticsearch στο λειτουργικό σύστημα αλλά και του kibana προκειμένου την καλύτερη επαφή με την κατανεμημένη μηχανή αναζήτησης και ανάλυσης.

Βασική προϋπόθεση είναι η σύνταξη συνάρτησης που θα επικοινωνεί το εκάστοτε πρόγραμμα της python με τη μηχανή αναζήτησης (*conn.py*). Έπειτα, χρησιμοποιώντας τη βιβλιοθήκη helpers της elasticsearch γίνεται το parse του εκάστοτε csv αρχείου έτσι ώστε να ανέβει στο περιβάλλον της elasticsearch με τον ορισμό συγκεκριμένου index (*upload.py*). Να σημειωθεί πως για την επιβεβαίωση του ανεβάσματος του csv αρχείου υλοποιήθηκε και ένα script που επιστρρέφει το πλήθος των τιμών με βάση το index name που ορίστηκε στη διαδικασία του upload (*checkIndex.py*). Η περίπτωση του upload ενός csv αρχείου αλλά και η περίπτωση του check μέσω indexname, γίνεται εύκολα από την *main.py* πληκτρολογώντας το επιθυμητό choice.

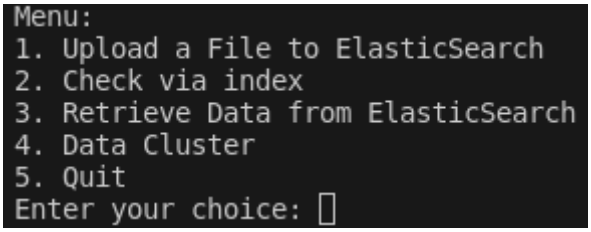

getDataS.py

Πρωτού εξηγηθεί το ερώτημα της εύρεσης βιβλίων με βάση αλφαριθμητικού-keyword, αριθμού-user_id για search είναι αναγκαία η επεξήγηση της “απλής” εύρεσης δηλαδή της συνάρτησης *getdata* λόγω του ότι είναι απαραίτητη για την επίλυση του ερωτήματος. Στο menu πλοήγησης του χρήστη ζητείται ένα keyword και έπειτα ζητά την 1η επιλογή που είναι αυτή της απλής αναζήτησης.

```
match_query = {
        "match": {
                "book_title": keyword
        }
}
result = cn.search(index=indexname, query=match_query)
```

Ο παραπάνω κώδικας ορίζει ένα ερώτημα αντιστοίχισης που αναζητά την παρεχόμενη λέξη-κλειδί στο πεδίο “book_title” του ευρετηρίου elasticsearch. Στη συνέχεια εκτελεί την αναζήτηση χρησιμοποιώντας το καθορισμένο ερώτημα και αποθηκεύει το αποτέλεσμα.

```
books = []
score = []
for hit in result['hits']['hits']:
        books.append(hit['_source'])
        score.append(hit['_score'])
```

Έπειτα για κάθε “χτύπημα” – αποτέλεσμα από τον πίνακα result που τέθηκε, εξάγει τα αποτελέσματα πηγής (στο πεδίο *_source*). Επίσης ανακτά το score (*_score*) για κάθε εύρημα. Τα εξαγόμενα αποτελέσματα αποθηκεύονται σε νέες λίστες που ορίστηκαν (*books, score*) και αυτό για να καθαρίσουμε το response της elasticsearch από μεταδεδομένα.

Τέλος δημιουργείται ένα dataframe από τα εξαγόμενα source data και προστίθεται μία στήλη με την ονομασία score στο dataframe.

getDataID.py

Σε αυτό το script υλοποιείται ο κώδικας για την απάντηση στο 1ο ερώτημα της εργασίας. Στο menu πλέον μετά την καταχώρηση του keyword επιλέγεται η 2η επιλογή που είναι η ανάκτηση αποτελεσμάτων με βάση ΚΑΙ το id του χρήστη, όπου εισάγεται και αυτό (υπάρχει και το βήμα της ενεργοποίησης νευρωνικού δικτύου αλλά προς το παρόν το αφήνουμε απενεργοποιημένο).

Πρώτα, δημιουργείται η συνάρτηση *getdataisbnUid* η οποία παίρνει τα δεδομένα που εισήγαγε ο χρήστης και αφετέρου φιλοξενεί την isbnRatingAvg η οποία επιστρέφει το μέσο όρο βαθμολογιών του βιβλίου. Ξεκινώντας από την αμφωλευμένη συνάρτηση, ένα γενικό σχόλιο γι αυτήν θα ήταν ο υπολογισμός του μέσου όρου ενός βιβλίου με βάση το αναγνωριστικό του βιβλίου και το αναγνωριστικό του χρήστη.

```
query = {
        "bool": {
                "must": [
                        {
                        "match": {
                                "isbn": book_code
                                }
                        }
                ],
                "should": [
                        {
                        "match": {
                                "uid": userId
                                }
                        }
                }
                ]
        }
}
```

Ο παραπάνω κώδικας ουσιαστικά πετυχαίνει το ταίριασμα μεταξύ κωδικού βιβλίου και χρήστη, με αποτέλεσμα να προωθεί το βιβλίο αν ο χρήστης το έχει διαβάσει (μιας και έχει βαθμολογία).

Έπειτα εκτελείται εύρεση χρησιμοποιώντας την search συνάρτηση της elasticsearch όπως και προηγουμένως, με την ιδιαιτερότητα πως στην περίπτωση που δεν υπάρχουν επιτυχίες (ταιριάσματα) στα αποτελέσματα αναζήτησης (δλδ δεν υπάρχουν βαθμολογίες για το βιβλίο), η συνάρτηση επιστρέφει 0 ως μέση βαθμολογία και βαθμολογία χρήστη. Αυτό γιατί στην περίπτωση που δεν υπολογιζόταν αυτή η πιθανότητα προέκυπτε σφάλμα υπερχείλησης.

Ορίζεται άθροισμα αξιολογήσεων (*sum*) και μετρητής του πλήθους των αξιολογήσεων (*counter*). Ανακτά τη βαθμολογία του χρήστη από το πρώτο ([0]) “χτύπημα” στα αποτελέσματα αναζήτησης που έγινε παραπάνω και την εκχωρεί στη μεταβλητή userRating. Στη συνέχεια, επαναλαμβάνει τις επιτυχίες στα αποτελέσματα αναζήτησης και ελέγχει αν κάθε βαθμολογία είναι μεγαλύτερη από 0. Αν ναι, προσθέτει την αξιολόγηση στο άθροισμα *sum* και αυξάνει τον μετρητή.

Τέλος, με μία if ελέγχεται το ενδεχόμενο για μετρητή ίσο με το μηδέν ώστε να μην διαιρεθεί ο μέσος όρος με μηδέν.

Αφού εξετάστηκε με επιτυχία ο μέσος όρος των αξιολογήσεων, η ροή μεταφέρεται στην εξωτερική συνάρτηση *getdataisbnUid*, στην οποία γίνεται σύνδεση με την elasticsearch και ανακτόνται τα βιβλία μέσω της συνάρτησης *getdata* της προηγούμενη υποενότητα (*getDataS.py*)· προκειμένου να φέρουμε όλα τα βιβλία με το συγκεκριμένο keyword. Καλείται η προηγούμενη συνάρτηση *isbnRatingAvg* για το isbn του βιβλίου, συμπληρώνονται οι λίστες των μέσο όρων και των ratings και ενημερώνεται η συμπληρομένη λίστα.

```
score = []
for i in range(len(books)):
    score += [(0.65 * books.loc[i, 'score']) + (0.25 * books.loc[i, 'rating']) + (0.1 * avgs[i])]
```

Στον παραπάνω κώδικα επαναλαμβάνεται κάθε βιβλίο στο πλαίσιο δεδομένων books DataFrame και υπολογίζει μια βαθμολογία με βάση έναν σταθμισμένο συνδιασμό της υπάρχουσας βαθμολογίας του βιβλίου (books.loc[i, ‘score’]), της βαθμολογίας του χρήστη (books.loc[i, ‘rating’]) και της μέσης βαθμολογίας (avgs[i]). Τα υπολογισμένα αποτελέσματα αποθηκεύονται στη λίστα αποτελεσμάτων.

```
return books.sort_values(by=['score'], ascending=False)
```

getDataID2.py

Στο αρχείο αυτό έγινε προσπάθεια για την ίδια παραπάνω υλοποίηση (retrieve data by id) με τη διαφορά ότι έγινε με τη χρήση aggregation.

```
query = {
        "query": {
                "match": {
                        "book_title": {
                                "query": keyword,
                                "operator": "and"
                        }
                }
        },
        "aggs": {
                "avg_rating": {
                        "avg": {
                                "field": "rating",
                        }
                }
        }
}
# Collecting all the data using Scan function.
rel = scan(
        client=cn,
        query=query,
        scroll='1m',
        index='merged',
        raise_on_error=True,
        preserve_order=False,
        clear_scroll=True
)
```

Ερώτημα Δεύτερο

Για την απάντηση αυτού του ερωτήματος χρησιμοποιήσαμε τα τρία παρακάτω scripts *fetchCluster.py*, *optimalK.py*, *dataCluster.py*.

fetchCluster.py

Η συνάρτηση του αρχείου, ανακτά δεδομένα από την Elasticsearch με βάση ένα προκαθορισμένο μέγεθος.

Αφού γίνει η σύνδεση με την Elasticsearch, ορίζεται το query ταιριάσματος (match_all) για την ανάκτηση όλων των εγγράφων από το ευρετήριο “books”. Με το πέρας της εκτέλεσης αποθηκεύονται στην μεταβητή result.

Οι λίστες, *summary* και *isbns* δημιουργούνται για την αποθήκευση των περιλήψεων αλλά και του id του βιβλίου. Η περίληψη και το ISBN κάθε βιβλίου εξάγονται από τα αποτελέσματα της αναζήτησης και προσαρτώνται στους αντίστοιχους καταλόγους.

Οι ρυθμίσεις του aggregation (aggr) ορίζονται για την ανάκτηση των κορυφαίων hits (χρηστών) για κάθε ISBN. Ο μέγιστος αριθμός hits ορίζεται μέχρι τα 100 και τα πεδία που συμπεριλαμβάνονται στην πηγή καθορίζονται ως [‘uid’, ‘rating’].

```
aggr = {
        "aggs": {
                "top_hits": {
                        "size": 100,
                        "_source": ['uid', 'rating']
                }
        }
}
```

Ο κώδικας επαναλαμβάνεται για κάθε *ISBN* και εκτελεί ένα ερώτημα αντιστοίχισης για να ανακτήσει τους users που βαθμολόγησαν το βιβλίο. Οι ανακληθέντες χρήστες και οι αξιολογήσεις αυτών αποθηκεύονται σε μια προσωρινή λίστα (temp_list). Εάν ο χρήστης υπάρχει (στα αποτελέσματα αναζήτησης), η τοποθεσία, η ηλικία και η βαθμολογία του εξάγονται και προστίθενται στην *temp_list*. Μετά την επανάληψη όλων των χρηστών για το τρέχον *ISBN*, η *temp_list* προσαρτάται στην κύρια λίστα χρηστών.

```
for hit in res['aggregations']['aggs']['hits']['hits']:
        match_user = {"match": {"uid": hit['_source']['uid']}}
        userRes = cn.search(index='users', query=match_user, size=1)
        if userRes['hits']['hits']:
                temp = userRes['hits']['hits'][0]['_source']
                temp_list.append((temp['location'], temp['age'], hit['_source']['rating']))
        users.append(temp_list)
```

Τέλος, δημιουργείται ένα *DataFrame* για την αποθήκευση των ανακτηθέντων δεδομένων, με στήλες για τη περίληψη και τους χρήστες και επιστρέφεται ως αποτέλεσμα συνάρτησης (return).

```
return pd.DataFrame({"summary": [s for s in summary], "users": [user for user in users]},
                                columns=['summary', 'users'])
```

optimalK.py

Μέσω της συνάρτησης find_opt_k του αρχείου και καθορίζει τον βέλτιστο αριθμό συστάδων (K) χρησιμοποιώντας τη μέθοδο Elbow. Η συνάρτηση λαμβάνει μια παράμετρο x, η οποία αντιπροσωπεύει τα δεδομένα για την ομαδοποίηση, ένα εύρος τιμών από 1 έως 14 ορίζεται με τη χρήση του range(1,15).

Αρχικοποιείται μια κενή λίστα για το άθροισμα τετραγωνικών σφαλμάτων (Sum_Squared_Errors) για την αποθήκευση των σφαλμάτων για κάθε τιμή του K.

Αφού γίνει η σύνδεση με την Elasticsearch, ορίζεται το query ταιριάσματος (match_all) για την ανάκτηση όλων των εγγράφων από το ευρετήριο “books”. Με το πέρας της εκτέλεσης αποθηκεύονται στην μεταβητή result.

Στην δομή ελέγχου, Δημιουργείται ένα μοντέλο *KMeans* με την τρέχουσα τιμή K χρησιμοπιώντας το *KMeans* (*n_clusters=k, n_init=10*). Προσαρμόζει το μοντέλο στα δεδομένα x χρησιμοποιώντρας το km. fit(x). Υπολογίζει το *Sum_Squared_Errors* (αδράνεια) του αποτελέσματος της ομαδοποίησης χρησιμοποιώντας το km.inertia_ και το προσθέτει στη λίστα του *Sum_Squared_Errors.*

Ο χρήστης μέσω της μεταβητής *choice* καλέιται αν θα σχεδιάσει το *Elbow* γράφημα. Εάν τεθεί θετικά ο κώδικας σχεδιάζει το γράφημα μέσω της *plt.plot(rng, Sum_Squared_Errors)* και εμφανίζεται.

Το *KneeLocator* από τη βιβλιοθήκη *kneed* χρησιμοποείται για την εύρεση της βέλτιστης τιμής K (σημείο *Elbow*) με βάση τις τιμές *Sum_Squared_Errors.* Η βέλτιστη τιμή K επιστρέφεται με τη χρήση του *kneel.elbow.*

dataCluster.py

Η συνάρτηση *clusterData* εκτελεί ομαδοποίηση και παράγει απεικονίσεις, λαμβάνοντας ως παραμέτρους *metric* και *userId*.

Η εμφολευημένη συνάρτηση *clr* ορίζεται για την επεξεργασία των δεδομένων για κάθε συστάδα. Η συνάρτηση *fetch_cluster* καλείται για να ανακτήσει τις περιλήψεις βιβλίων και να τις αποθηκεύσει στο πλαίσιο δεδομένων *DataFrame.*

Οι περιλήψεις μετατρέπονται σε διανύσματα με τη χρήση του *CountVectorizer* και αποθηκεύονται στον πίνακα A. Η μείωση της διαστατικότητας πραγματοποιείται στα διανύσματα με τη χρήση *PCA* (Ανάλυση Κύριων Συνιστωσών), με αποτέλεσμα το a*Svd*.

Η βέλτιστη τιμή K προσδιορίζεται με τη συνάρτηση *find_opt_k*. Ανάλογα με την μετρική παράμετρο, η ομαδοποίηση πραγματοποιείται είτε με ομοιότητα συνημιτόνου είτε με ευκλείδεια απόσταση με τη χρήση του *Kmeans*.

Οι ετικέτες των συστάδων αντιστοιχίζονται στο πλαίσιο δεδομένων *df*. Λαμβάνονται μοναδικές ετικέτες συστάδων και χρησιμοποιούνται για την απεικόνιση των αποτελεσμάτων. Κάθε συστάδα απεικονίζεται ως διάγραμμα διασποράς, με σημειωμένα τα κεντροειδή.

Οι χάρτες θερμότητας δημιουργούνται για κάθε συστάδα χρησιμοποιώντας τη συνάρτηση *clr* για την επεξεργασία των δεδομένων και τη συνάρτηση *heatmap* του *seaborn* για τη δημιουργία της απεικόνισης.

Σημείωση:

/home/jsaillok/.local/lib/python3.10/site-packages/sklearn/cluster/_kmeans.py:870: FutureWarning: The default value of `n_init` will change from 10 to 'auto' in 1.4. Set the value of `n_init` explicitly to suppress the warning

warnings.warn(

Λόγω του συγκεκριμένου warning προστέθηκε η αρχικοποιήση της τιμής *Kmeans(n_init=10)*.

Ερώτημα Τρίτο

teachUser.py

Στο αρχείο αυτό με τον ορισμό της συνάρτησης *teach_user(userId)* ανακτά δεδομένα από την Elasticsearch που αφορούν τον χρήστη από ένα ευρετήριο και τα μετατρέπει σε ένα πλαίσιο δεδομένων pandas DataFrame.

Εκτελεί query στη στο ευρετήριο με όνομα *"bratings"* για να ανακτήσει δεδομένα αξιολόγησης χρηστών με βάση το userId. Το ερώτημα αναζήτησης ταιριάζει το πεδίο uid με το userId και η παράμετρος size περιορίζει τον αριθμό των αποτελεσμάτων σε 10.000.

```
rs = cn.search(index='bratings', query={"match": {"uid": userId}}, size=10000)
```

Ο κώδικας επαναλαμβάνει τα αποτελέσματα της αναζήτησης και εξάγει τις τιμές isbn και rating από κάθε εύρημα. Δημιουργεί μια πλειάδα (isbn, rating) και την προσθέτει στη λίστα του πίνακα. Αυτό το βήμα φιλτράρει τις αξιολογήσεις με τιμή "0".

```
array = []
# get all the books(isbn) for a user into a list
for hit in rs['hits']['hits']:
        # keep rated by user books
        userRating = int(hit['_source']['rating'])
        if userRating:
                isbn_rating = (hit['_source']['isbn'], userRating)
                array.append(isbn_rating)
```

Με δομή επανάληψης επαναλαμβάνεται ο πίνακας των πλειάδων και για κάθε πλειάδα εκτελεί ένα άλλο ερώτημα αναζήτησης με όνομα *"books"* για την ανάκτηση πληροφοριών του βιβλίου με βάση την τιμή *isbn*.

Ελέγχει αν τα αποτελέσματα της αναζήτησης δείχνουν ότι το βιβλίο υπάρχει (rs['hits'] ['total']['value'] μεγαλύτερο του 0). Εάν το βιβλίο υπάρχει, εξάγει τις τιμές bookk_title, summary και isbn από κάθε εύρημα και τις προσθέτει στις αντίστοιχες λίστες (*book_titles, summaries, book_isbn*). Προσθέτει επίσης την αντίστοιχη βαθμολογία από τον πίνακα στη λίστα βαθμολογιών.

```
for t in array:
        rs = cn.search(index='books', query={"match": {"isbn": t[0]}})
        # if specific book exists in index 'books'
        if rs['hits']['total']['value']:
                # get the rating
                ratings.append(int(t[1]))

                for hit in rs['hits']['hits']:
                        book_titles += [hit['_source']['book_title']]
                        summaries += [hit['_source']['summary']]
                        book_isbn += [hit['_source']['isbn']]
```

Τέλος, δημιουργείται ένα λεξικό d με τις συλλεγμένες λίστες δεδομένων (*book_titles, ratings, summaries, book_isbn*) ως τιμές και τα αντίστοιχα ονόματα στηλών (*isbn, book_title, summary, ratings*) ως κλειδιά. Χρησιμοποιείται το λεξικό για τη δημιουργία πλαισίου δεδομένων pandas DataFrame και το επιστρέφει.

```
d = {'isbn': book_isbn, 'book_title': book_titles, 'summary': summaries, 'rating': ratings}
```

teachData.py

Μέσω της συνάρτησης teach_data (userId, zero_books) του ορισμένου αρχείου εκπαιδεύεται ένα μοντέλο μηχανικής μάθησης χρησιμοποιώντας δεδομένα που αφορούν συγκεκριμένους χρήστες και προβλέπει βαθμολογίες για ένα σύνολο βιβλιών με μηδενική βαθμολογία. Το αποτέλεσμα της κλήσης ανατίθεται στη μεταβλητή user_nz_data (περιέχονται δεδομένα βιβλίων για κάθε χρήστη που αποκλείουν τα βιβλία με βαθμολογία 0).

Έπειτα ελέγχεται αν ο αριθμός των ειδικών για τον χρήστη βιβλίων είναι μικρότερος ή ίσος με 1. Εάν ναι, τότε εμφανίζεται μια εξαίρεση που υποδεικνύει ότι τα δεδομένα εκπαίδευσης του χρήστη δεν είναι επαρκή.

```
if len(user_nz_data) <= 1:
        raise Exception("User's train data are not enough")
```

Συνδέονται οι στύλες *book_title* και *summary* του *user_nz_data* σε μια νέα στήλη με όνομα *title_sumamry*.

```
user_nz_data['title_summary'] = user_nz_data['book_title'] + ' ' + user_nz_data['summary']
```

Διαχωρίζονται τα δεδομένα που αφορούν συγκεκριμένο χρήστη σε σύνοκα εκπαίδευσης και δοκιμής χρησιμοποιώντας τη συνάρτηση train_test_split. Επιλέγονται οι στήλες title_summary και *rating* για διαχωρισμό, με το 70% των δεδομένωννα χρησιμοποιείται για εκπαίδευση (training) και το 30% για δοκιμή (testing). Η παράμετρος *random_state* ορίζεται σε 42 λόγους αναπαραγωγικότητας. Εξάγονται οι τιμές *title_summary* και *rating* από τα σύνολα εκπαίδευσης και δοκιμής και τις αποθηκεύει σε ξεχωριστές λίστες.

```
train, test = train_test_split(user_nz_data.loc[:, ['title_summary', 'rating']], test_size=0.3,
random_state=42)
```

Για τη μετατροπή των δεδομένων κειμένου στα *train_x και test_x* σε αριθμητικά διανύσματα χαρακτηριστικών δημιουργείται αντικείμενο *CountVectorizer.* Προσαρμόζεται ο διανυσματοποιητής στα δεδομένα εκπαίδευσης χρησιμοποιώντας την *fit_transform* και μετασχηματίζει τα δεδομένα δοκιμής χρησιμοποιώντας την *transform.*

```
vectorizer = CountVectorizer()
train_x_vectors = vectorizer.fit_transform(train_x)
test_x_vectors = vectorizer.transform(test_x)
```

Έπειτα, για την κλιμάκωση των διανυσμάτων χαρακτηριστικών δημιουργείται ένα αντικείμενο *MaxAbsScaler.* Προσαρμόζεται ο *scaler* στα δεδομένα εκπαίδευσης με τη χρήση *fit_transorm* και μετασχηματίζεται στα δεδομένα δοκιμής με τη χρήση *transform.*

```
scaler = MaxAbsScaler()
train_x_vectors = scaler.fit_transform(train_x_vectors)
test_x_vectors = scaler.transform(test_x_vectors)
```

Αναφορικά με την ταξινόμηση, αρχικοποιούνται τέσσερις ταξινομητες (*RandomForestClassifier, LogisticRegression, DecisionTreeClassifier, SVC*) και εκπαιδεύονται χρησιμοποιώντας κλιμακωτά δεδομένα εκπαίδευσης (*train_x_vectors, train_y*).

```
clf_rfc = RandomForestClassifier()
clf_log = LogisticRegression()
clf_dec = DecisionTreeClassifier()
clf_svm = svm.SVC(kernel='linear', C=4)
clf_rfc.fit(train_x_vectors, train_y)
```

Τέλος, εκτυπώνονται οι μέσες ακρίβειες των εκπαιδευμένων ταξινομημένων στα δεδομένα δοκιμής. Συνδέονται οι στήλες *book_title* και *summary* της *zero_books* σε μια νέα λίστα *zero_books_x.* Μετασχηματίζονται τα *zero_books_x* μέσω του προσαρμοσμένου διανυσματικού

μετασχηματιστή έτσι ώστε να ληφθούν τα διανύσματα χαρακτηριστικών για τα βιβλία με μηδενική διαβάθμιση (*zero_books_x_vectors*). Με βάση την επιλογή του χρήστη επιστρέφονται οι προβλεπόμενες βαθμολογίες για τα βιβλία με μηδενική βαθμολογία χρησιμοποιώντας τον αντίστοιχο ταξινομητή.

Περιγραφή Γραφικού Περιβάλλοντος

Όπως προαναφέρθηκε υλοποιήθηκε και GUI (Graphical User Interface) για διάφορες υλοποίησεις του συγκεκριμένου project.

Συγκεκριμένα, ανέβασμα ενός csv αρχείου, έλεγχος επιτυχούς ανεβάσματος μέσω του index του αρχείου

Όπως προαναφέρθηκε στην ενότητα περιγραφή περιβάλλοντος υλοποίησης υλοποιήθηκε και GUI (Graphical User Interface) για διάφορες υλοποιήσεις του συγκεκριμένου project.

Συγκεκριμένα, ανέβασμα ενός csv αρχείου, έλεγχος επιτυχούς ανεβάσματος μέσω index που περιγράφει το αρχείο και ανάκτηση δεδομένων με εισαγωγή λέξης κλειδί, ήταν αυτές που διεκπεραιώθηκαν.

Ακολουθούν mock-ups:

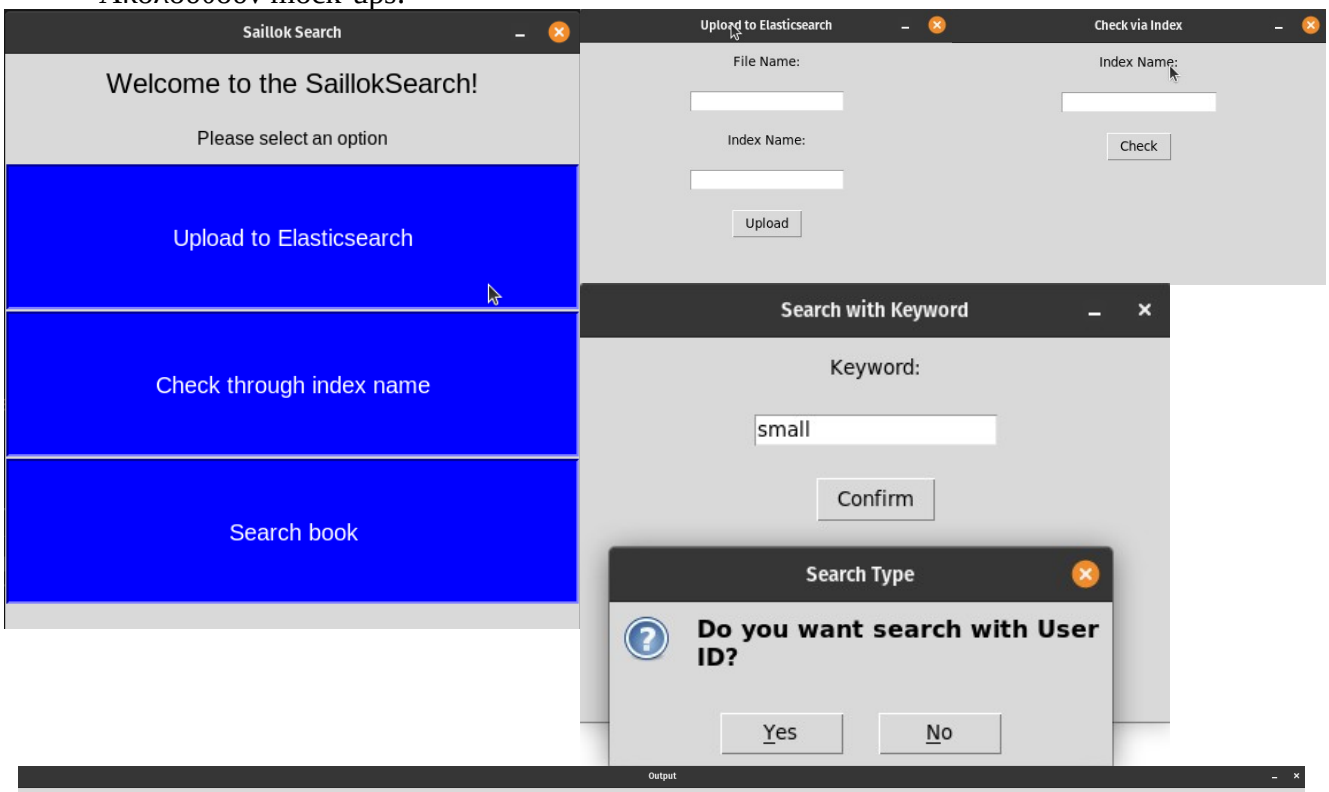

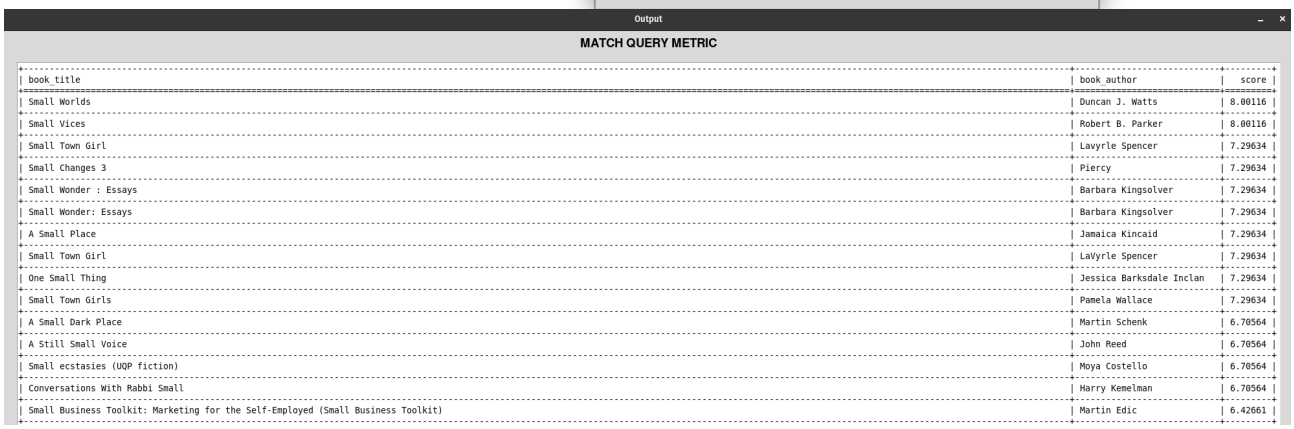

Περιγραφή Αποτελεσμάτων Υλοποίησης

Ως καλύτερες τιμές testing που χρησιμοποιήθηκαν, δημιουργήθηκε ένα script που να βρίσκει στο csv αρχείο των Ratings το uid με τις περισσότερες κριτικές (common.py).

Ερώτημα Πρώτο

```
Menu:
1. Upload a File to ElasticSearch
2. Check via index
3. Retrieve Data from ElasticSearch
4. Data Cluster
5. Quit
Enter your choice: 3
Give the keyword: small
1. Search with simply metric
2. Search with uid metric
Choice: 2
Give user id: 11676
Use neural network? [Y/n]: n
```

```
==============================MATCH QUERY METRIC THROUGH USER ID==============================
                                      book_title               book_author     score
5                                Small Wonder: Essays         Barbara Kingsolver  8.098175
0                                        Small Worlds            Duncan J. Watts  8.000751
4                               Small Wonder : Essays         Barbara Kingsolver  7.846465
2                                     Small Town Girl            Lavyrle Spencer  7.720205
3                                     Small Changes 3                     Piercy  7.542619
16                            The God of Small Things               Arundhati Roy  7.291484
17                           Notes from a Small Island                 Bill Bryson  6.584225
10                                 A Small Dark Place               Martin Schenk  6.441999
33  Don't Sweat the Small Stuff and It's All Small...             Richard Carlson  5.533744
1                                        Small Vices             Robert B. Parker  5.200751
15                            The God of Small Things               Arundhati Roy  4.800266
9                                    Small Town Girls              Pamela Wallace  4.742619
7                                     Small Town Girl             LaVyrle Spencer  4.742619
8                                     One Small Thing    Jessica Barksdale Inclan  4.742619
6                                       A Small Place              Jamaica Kincaid  4.742619
11                             A Still Small Voice                    John Reed  4.358666
13                   Conversations With Rabbi Small               Harry Kemelman  4.358666
12                    Small ecstasies (UQP fiction)                Moya Costello  4.358666
25                Don't Sweat the Small Stuff in Love             Richard Carlson  4.290258
14  Small Business Toolkit: Marketing for the Self...                 Martin Edic  4.177297
19                           A Small Book of Fairies               Eugene Stiles  4.032225
20                        All Creatures Great and Small               James Herriot  4.032225
21          Small Gods (Discworld Novels (Paperback))              Terry Pratchett  4.032225
22                       Small Hours of the Morning                        Yorke  4.032225
23                         The Small Rain : A Novel           Madeleine L'Engle  4.032225
18                        Notes from a Small Island                 Bill Bryson  4.032225
24                First Test (Protector of the Small)               Tamora Pierce  3.751274
26                       Small Pig (I Can Read Book 2)                Arnold Lobel  3.506924
27                Mr. Small (Mr. Men and Little Miss)             Roger Hargreaves  3.506924
28          Any Small Goodness: A Novel of the Barrio                Tony Johnston  3.292460
30  Friday the Rabbi Slept Late (Rabbi Small Mystery)               Harry Kemelman  3.292460
31            The Large, the Small and the Human Mind                Roger Penrose  3.292460
32           Any Small Thing Can Save You: A Bestiary              Christina Adam  3.292460
29  Sunday the Rabbi Stayed Home (Rabbi Small Myst...               Harry Kemelman  3.292460
34  Runamok: A Novel About the Realities of Small ...                    Tom Park  3.102716
35  Girl Named Zippy: Growing Up Small in Moorelan...                  Haven Kimmel  3.102716
36  Idyll Banter : Weekly Excursions to a Very Sma...               CHRIS BOHJALIAN  3.102716
37  Small Sacrifices: A True Story of Passion and ...                      Ann Rule  3.102716
38      Hope's Edge: The Next Diet for a Small Planet          Frances Moore Lappe  3.102716
44  Don't Sweat the Small Stuff at Work : Simple W...                Richard Carlson  3.097188
39  Lasagna Gardening for Small Spaces : A Layerin...                 Patricia Lanza  3.096239
40  A Still, Small Voice: A Practical Guide on Rep...  Benedict J., Fr. Groeschel  2.933650
42  Working in a Very Small Place: The Making of a...               Mark L. Shelton  2.782056
41  The City Gardener's Handbook: The Definitive G...                    Linda Yang  2.782056
43  Small Patchwork Projects: With Step-By-Step In...            Barbara. Brondolo  2.645359
45  Moving To A Small Town : A Guidebook To Moving...                Wanda Urbanska  2.408660
46  Don't Sweat the Small Stuff in Love : Simple W...               Richard Carlson  2.352223
47  A Girl Named Zippy: Growing Up Small in Moorel...                  HAVEN KIMMEL  2.305515
48  Ozarks: The Hills Are Alive With Small Towns a...              Hannah Alexander  2.210840
49  Grassroots Organizations: A Resource Book for ...              Robert L. Clifton  2.210840
50  A Death in Texas: A Story of Race, Murder, and...             Dina Temple-Raston  2.210840
51  BLOW: How a Small-Town Boy Made $100 Million w...                   Bruce Porter  2.043048
52  The INVENTION THAT CHANGED THE WORLD: HOW A SM...                  Robert Buderi  1.773802
============================================================================================
```

Ερώτημα Δεύτερο

```
Menu:
1. Upload a File to ElasticSearch
2. Check via index
3. Retrieve Data from ElasticSearch
4. Data Cluster
5. Quit
Enter your choice: 4
1. Euclidean Distance
2. Cosine Similarity
Choice: 1
Books to fetch: 5000
Plot Elbow Graph? (Y/N) --> y
```

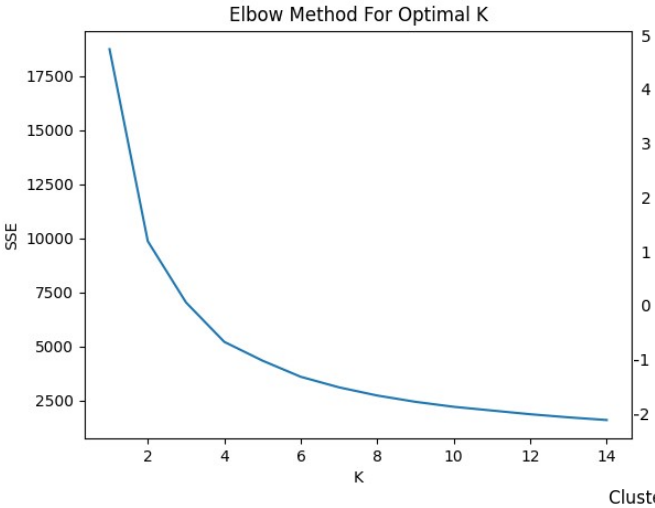

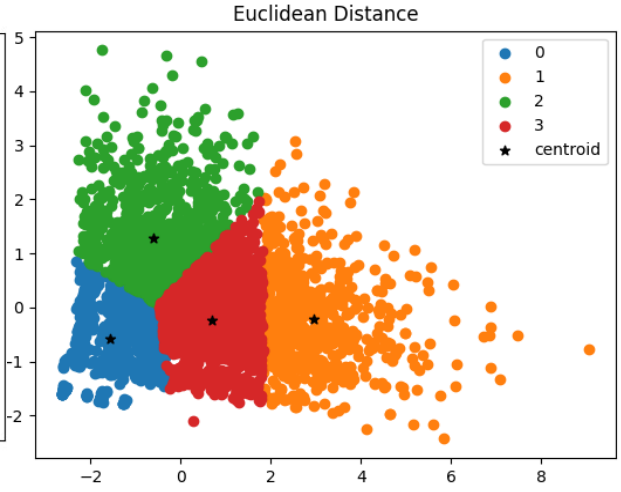

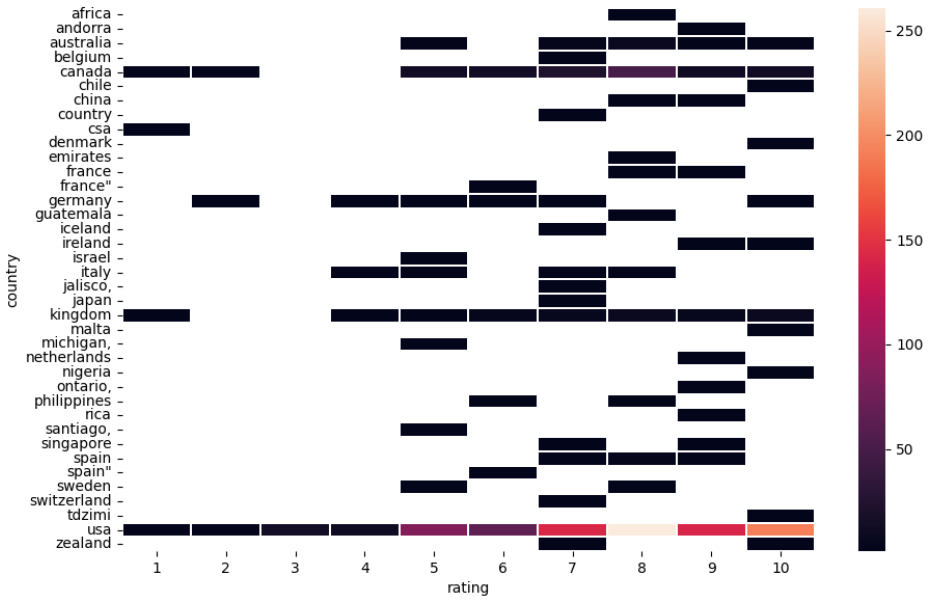

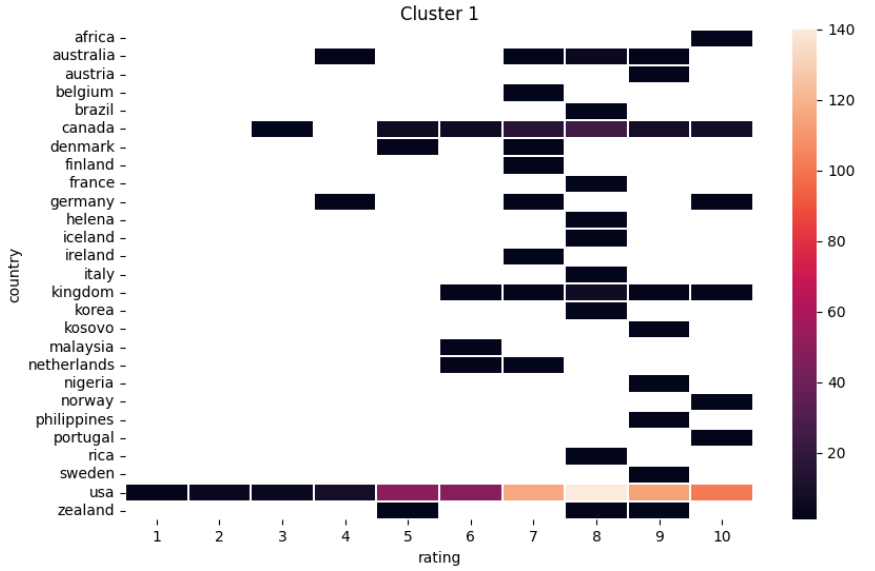
Cluster 1
africa
australia
austria
belgium
brazil
canada
denmark
finland
france
germany
helena
iceland
ireland
italy
kingdom
korea
kosovo
malaysia
netherlands
nigeria
norway
philippines
portugal
rica
sweden
usa
zealand
country
1
2
3
4
5
6
7
8
9
10
rating
140
120
100
80
60
40
20

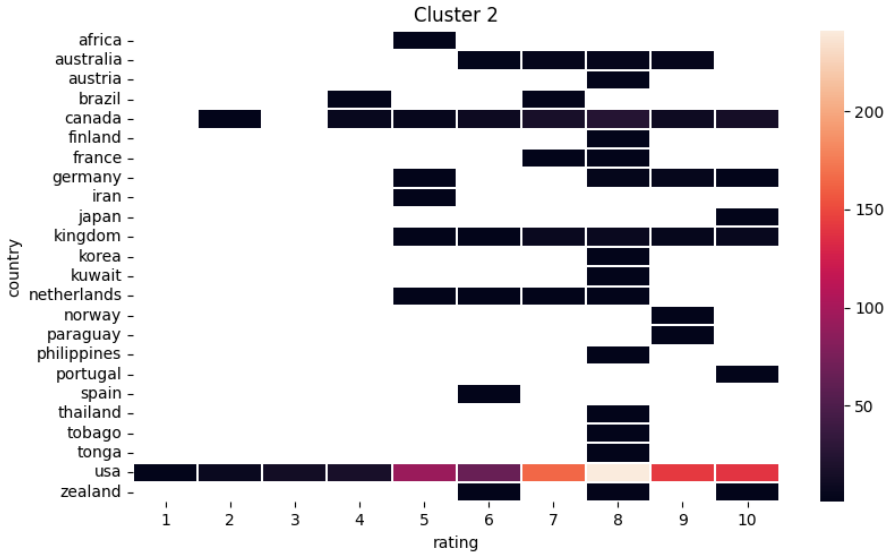
Cluster 2
africa
australia
austria
brazil
canada
finland
france
germany
iran
japan
kingdom
korea
kuwait
netherlands
norway
paraguay
philippines
portugal
spain
thailand
tobago
tonga
usa
zealand
country
1
2
3
4
5
6
7
8
9
10
rating
200
150
100
50

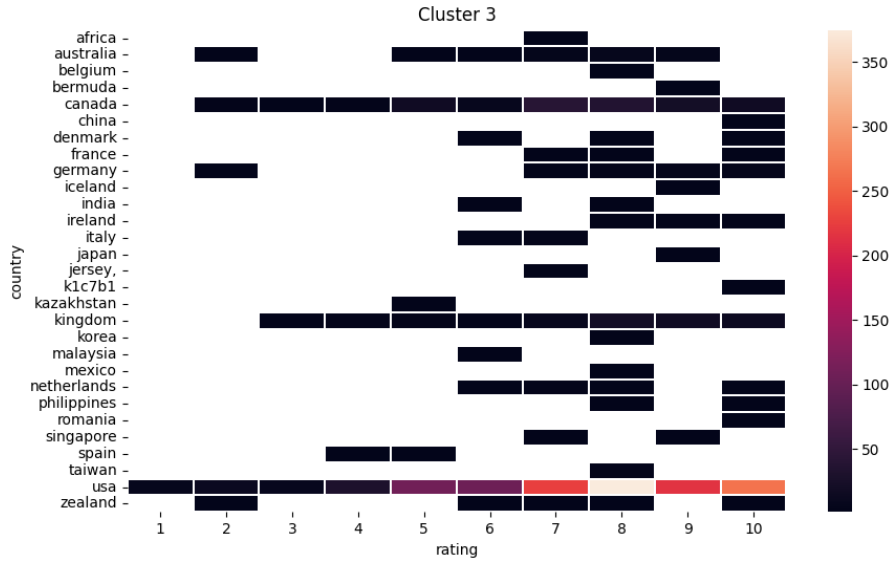
Cluster 3
africa
australia
belgium
bermuda
canada
china
denmark
france
germany
iceland
india
ireland
italy
japan
jersey,
k1c7b1
kazakhstan
kingdom
korea
malaysia
mexico
netherlands
philippines
romania
singapore
spain
taiwan
usa
zealand
country
1
2
3
4
5
6
7
8
9
10
rating
350
300
250
200
150
100
50

Ερώτημα Τρίτο

```
Menu:
1. Upload a File to ElasticSearch
2. Check via index
3. Retrieve Data from ElasticSearch
4. Data Cluster
5. Quit
Enter your choice: 3
Give the keyword: small
1. Search with simply metric
2. Search with uid metric
Choice: 2
Give user id: 11676
Use neural network? [Y/n]: y
564 243
Mean Accuracies:
1. RandomForest:  0.2345679012345679
2. LogisticRegression:  0.18106995884773663
3. DecisionTree:  0.18930041152263374
4. SVM:  0.1934156378600823
Classifier: 3
==============================MATCH QUERY METRIC THROUGH USER ID==============================
                                        book_title                book_author     score
5                                Small Wonder: Essays          Barbara Kingsolver  8.098175
0                                        Small Worlds             Duncan J. Watts  8.000751
4                               Small Wonder : Essays          Barbara Kingsolver  7.846465
2                                     Small Town Girl             Lavyrle Spencer  7.720205
3                                     Small Changes 3                      Piercy  7.542619
16                           The God of Small Things                Arundhati Roy  7.291484
8                                     One Small Thing    Jessica Barksdale Inclan  6.992619
1                                        Small Vices            Robert B. Parker  6.950751
13                    Conversations With Rabbi Small              Harry Kemelman  6.858666
15                           The God of Small Things                Arundhati Roy  6.800266
6                                      A Small Place              Jamaica Kincaid  6.742619
9                                   Small Town Girls              Pamela Wallace  6.742619
17                         Notes from a Small Island                 Bill Bryson  6.584225
7                                     Small Town Girl             LaVyrle Spencer  6.492619
10                               A Small Dark Place                Martin Schenk  6.441999
11                              A Still Small Voice                     John Reed  6.358666
25               Don't Sweat the Small Stuff in Love              Richard Carlson  6.290258
21         Small Gods (Discworld Novels (Paperback))              Terry Pratchett  6.282225
20                    All Creatures Great and Small                James Herriot  6.282225
18                         Notes from a Small Island                 Bill Bryson  6.032225
19                           A Small Book of Fairies               Eugene Stiles  6.032225
26                    Small Pig (I Can Read Book 2)                Arnold Lobel  6.006924
12                    Small ecstasies (UQP fiction)               Moya Costello  5.858666
30  Friday the Rabbi Slept Late (Rabbi Small Mystery)              Harry Kemelman  5.792460
22                         Small Hours of the Morning                       Yorke  5.782225
23                           The Small Rain : A Novel          Madeleine L'Engle  5.782225
24               First Test (Protector of the Small)              Tamora Pierce  5.751274
38     Hope's Edge: The Next Diet for a Small Planet        Frances Moore Lappe  5.602716
32          Any Small Thing Can Save You: A Bestiary              Christina Adam  5.542460
33  Don't Sweat the Small Stuff and It's All Small...              Richard Carlson  5.533744
14  Small Business Toolkit: Marketing for the Self...                  Martin Edic  5.427297
35  Girl Named Zippy: Growing Up Small in Moorelan...                Haven Kimmel  5.352716
28         Any Small Goodness: A Novel of the Barrio                Tony Johnston  5.292460
29  Sunday the Rabbi Stayed Home (Rabbi Small Myst...              Harry Kemelman  5.292460
31           The Large, the Small and the Human Mind                Roger Penrose  5.292460
37  Small Sacrifices: A True Story of Passion and ...                     Ann Rule  5.102716
39  Lasagna Gardening for Small Spaces : A Layerin...              Patricia Lanza  5.096239
42  Working in a Very Small Place: The Making of a...              Mark L. Shelton  5.032056
44  Don't Sweat the Small Stuff at Work : Simple W...              Richard Carlson  4.847188
27               Mr. Small (Mr. Men and Little Miss)            Roger Hargreaves  4.756924
34  Runamok: A Novel About the Realities of Small ...                    Tom Park  4.602716
47  A Girl Named Zippy: Growing Up Small in Moorel...                HAVEN KIMMEL  4.555515
40  A Still, Small Voice: A Practical Guide on Rep...  Benedict J., Fr. Groeschel  4.433650
36  Idyll Banter : Weekly Excursions to a Very Sma...             CHRIS BOHJALIAN  4.352716
41  The City Gardener's Handbook: The Definitive G...                  Linda Yang  4.282056
48  Ozarks: The Hills Are Alive With Small Towns a...           Hannah Alexander  4.210840
49  Grassroots Organizations: A Resource Book for ...           Robert L. Clifton  4.210840
46  Don't Sweat the Small Stuff in Love : Simple W...              Richard Carlson  4.102223
45  Moving To A Small Town : A Guidebook To Moving...                Wanda Urbanska  3.908660
43  Small Patchwork Projects: With Step-By-Step In...           Barbara. Brondolo  3.895359
51  BLOW: How a Small-Town Boy Made $100 Million w...                Bruce Porter  3.793048
50  A Death in Texas: A Story of Race, Murder, and...          Dina Temple-Raston  3.710840
52  The INVENTION THAT CHANGED THE WORLD: HOW A SM...                Robert Buderi  3.523802
==============================================================================================
```

Γενικά Συμπεράσματα

Αρχικά είναι εμφανές πως τα αποτελέσματα του *score* στην απλή αναζήτηση της elasticsearch, συγκριτικά με την δημιουργία νευρωνικού διαφέρει. Αυτο παρατηρείται στις τιμές που παίρνει το score. Είναι πλέον πιο ομαλή η μετάβαση των τιμών του score από βιβλίο σε *βιβλίο* συγκριτικά με το πλήθος των τιμών στην απλή αναζήτηση που κυμαίνονται στο ίδιο score (~4).

Επομένως, η χρήση του νευρονικού βελτιώνει κατά πολύ την αναζήτηση συγκριτικά με ένα απλό αλγόριθμο, πόσο μάλλον με την εύρεση του μέσου και την ταξινόμηση στον πίνακα των αποτελεσμάτων.

Αναφορικά τώρα με το ερώτημα των kmeans, βλέπουμε και στο γράφημα των περιοχών του cluster πως ο διαχωρισμό τους είναι εμφανής για 5000 στοιχεία μόνο που το heat map αποκτά “χρώμα” μόνο για τη χώρα των Ηνωμένων Πολιτειών Αμερικής, κάτι το οποίο πιθανότατα ωφείλεται στη δειγματοληψία (dataset) των χρηστών.

Σας Ευχαριστώ